

合同段落变更类型识别服务

项目业务与接口说明

历史样本导入 · 统一 Embedding 网关 · JVM 内存检索
多标签加权投票 · Oracle 持久化

项目	内容
文档版本	V1.0（交付版）
适用项目	glxt-service-contract-change 1.0.0
技术基线	Java 8 / Spring Boot 2.1.5 / Oracle 11g
编制日期	2026 年 8 月 27 日

交付范围： 本文档以当前代码实现为准，覆盖业务边界、四个业务接口、模型网关契约、配置、数据库、部署、错误处理和验收。

目录

1. 项目说明与业务边界
2. 总体架构与核心流程
3. 公共调用约定
4. 历史样本 Excel 导入接口
5. 新合同段落预测接口
6. 内存索引运维接口
7. 统一 Embedding 模型网关
8. 业务算法与结果解释
9. 配置项说明
10. Oracle 数据结构与数据一致性
11. 部署、启动与模型迁移
12. 错误处理、日志与安全
13. 联调与验收清单
14. 附录：调用示例与 Excel 模板

阅读建议：业务调用方重点阅读第 3 至 6 章；开发人员重点阅读第 7 至 10 章；部署与运维人员重点阅读第 9 至 12 章。

1. 项目说明与业务边界

本服务利用已经确认过的历史合同段落及其变更类型编码，识别新合同段落可能对应的一个或多个变更类型。历史样本通过 Excel 导入，向量保存到 Oracle；预测时在 JVM 内存中进行精确向量比较。

1.1 业务目标

- 保存“历史合同段落—变更类型编码”的稳定对应关系。
- 对新段落优先做完全相同文本匹配，未命中时再进行语义相似度检索。
- 从最相似的历史段落标签中综合判断新段落的多个候选变更类型。
- 返回类型得分、可信等级和参考历史段落，便于调用方理解结果来源。

1.2 第一版明确边界

边界项	当前约定
输入粒度	每次输入已经切分好的单个合同段落；不解析整份 PDF 或 Word。
历史数据	第一张 Sheet 固定两列，单次最多 1000 条，累计物理记录最多 10000 条。
变更类型	只使用稳定的类型编码；不依赖 TPIF_XBGHTZJ，不查询类型名称和层级。
检索方式	JVM 内存逐条计算，不引入向量数据库或 HNSW。
模型能力	调用公司内网统一 Embedding 网关，本项目不部署 Python 服务或模型容器。
预测留痕	预测结果不入库，不建设任务表、反馈表和人工确认表。
部署形态	第一版按单个 Java 实例设计；多实例时需要额外解决各实例索引同步。

1.3 技术组成

组件	说明
应用框架	Java 8, Spring Boot 2.1.5.RELEASE

组件	说明
数据访问	MyBatis-Plus 3.4.3.4；业务 SQL 全部写在 XML 中
数据库	Oracle 11g；一张业务表、一条 Sequence、一个普通索引
Excel	Apache POI 4.1.2；仅支持.xlsx
接口文档	Springfox Swagger 2.9.2
模型	公司内网统一 Embedding 网关；Qwen3-Embedding-8B 部署

2. 总体架构与核心流程

合同段落变更类型识别业务闭环



图1 合同段落变更类型识别业务闭环

2.1 历史样本导入主流程

1. 校验上传文件、xlsx 扩展名、表头、行数、段落长度和类型编码。
2. 规范化合同段落，计算 SHA-256，并检查 Excel 内部重复或标签冲突。
3. 分批查询 Oracle，判断新增、幂等跳过、模型版本更新或标签冲突。
4. 按照 batch-size 调用统一模型网关，校验维度和数值并执行 L2 归一化。
5. 全部向量生成成功后，在一个数据库事务中新增或更新全部记录。
6. 事务提交后从 Oracle 重建 JVM 内存索引，并原子替换旧快照。

事务原则：模型调用发生在数据库事务之前。任何一批模型调用失败，本次 Excel 不会写入数据库；数据库写入阶段任意一条失败，整批回滚。

2.2 新段落预测主流程

- 1. 使用与导入相同的规则规范化文本并计算 Hash。
- 2. Hash 完全命中时直接返回历史类型，跳过模型调用。
- 3. 未命中且索引可用时，调用模型生成新段落的 1024 维向量。
- 4. 将新段落向量与当前内存中的历史段落向量逐条比较，保留前 10 条。
- 5. 过滤相似度低于 0.60 的记录，对前 10 条可靠记录执行平方加权投票。
- 6. 返回达到阈值的类型、可信等级以及最多 5 条参考历史段落。

重要澄清：新段落只与历史段落进行向量比较，不会与变更类型编码做向量比较。变更类型编码只是历史段落已经确认的标签。

3. 公共调用约定

3.1 服务地址

项目	值
默认端口	8080，可由 SERVER_PORT 覆盖
服务上下文	/glxt-service-contract-change
业务接口前缀	/service/contract-change
Swagger UI	/glxt-service-contract-change/swagger-ui.html
Actuator	/glxt-service-contract-change/actuator/health

3.2 统一响应结构

```
{
  "code": 200,
  "message": "操作成功",
  "data": {}
}
```

字段	类型	说明
code	Integer	业务响应码；调用方必须优先判断该字段。
message	String	可向操作人员展示的结果说明。
data	Object / null	成功数据，或 Excel 校验失败时的结构化错误详情。

3.3 业务响应码

code	含义	常见场景
200	处理成功	导入成功、预测成功、索引操作成功。
400	参数或业务校验失败	缺少 UserId、Excel 格式错误、标签冲突、段落超长。
500	未预期的系统错误	数据库或代码内部出现未处理异常。
503	依赖服务不可用	模型网关不可用、索引不可用。

HTTP 状态说明：当前实现通过统一 JSON 响应体返回业务结果，业务异常通常仍由 HTTP 200 承载。调用方不要只判断 HTTP 状态，必须判断响应体 code。

3.4 UserId 请求头

- 历史样本导入和段落预测必须携带 UserId，值为实际操作人工号。
- 服务将 UserId 透传到模型网关的 UserId 请求头，用于模型平台审计。
- UserId 不写数据库、不输出日志；索引状态和索引重载不需要该请求头。
- 调用方 Authorization 不会转发到模型平台；模型 Bearer Token 来自服务端 EMBEDDING_API_KEY。

4. 历史样本 Excel 导入接口

项目	说明
接口	POST /service/contract-change/samples/import

项目	说明
完整路径	/glxt-service-contract-change/service/contract-change/samples/import
Content-Type	multipart/form-data
必填请求头	UserId: 实际操作人工号
表单字段	file: .xlsx 文件
执行方式	同步执行; 请求等待到模型调用、入库和索引刷新完成。

4.1 Excel 格式

只读取第一张 Sheet 的前两列，首行表头必须完全一致。整行为空时跳过，不计入数据行数。

合同段落	变更类型编码
历史段落 A	TYPE01;TYPE02;TYPE03
历史段落 B	TYPE05;TYPE09

- 类型编码可使用英文分号、中文分号、英文逗号或中文逗号分隔；入库前统一为英文分号。
- 类型编码会去空、去重并按字典序排序；单个编码最长 64 字符，总长度最长 4000 字符。
- 编码内部不能包含空白字符。
- 规范化后的合同段落默认最多 2000 字符；超过时明确拒绝，不自动截断。
- 文件最大 20MB；单次最多 1000 个非空数据行。

4.2 重复、更新与冲突规则

情况	处理结果
Excel 内相同段落、相同类型	保留第一条，后续行计入 skipped。
Excel 内相同段落、不同类型	整批校验失败，返回首次出现行号。
数据库已有相同段落、相同类型、当前模型/维度且生效	幂等跳过，计入 skipped。

情况	处理结果
数据库已有相同段落、相同类型，但停用或模型/维度变化	重新生成向量、更新原记录并启用，计入 updated。
数据库已有相同段落、不同类型	整批拒绝，不静默覆盖历史标签。
新增后物理记录将超过 10000 条	拒绝导入；更新旧记录不增加物理记录数。

4.3 成功响应

```
{
  "code": 200,
  "message": "操作成功",
  "data": {
    "success": true,
    "totalRows": 3,
    "inserted": 2,
    "updated": 0,
    "skipped": 1,
    "indexReloaded": true,
    "errors": []
  }
}
```

字段	说明
success	本批是否通过校验并完成数据库写入。
totalRows	Excel 实际读取的非空数据行数。
inserted	新增记录数。
updated	重新启用或按当前模型重新生成向量的记录数。
skipped	Excel 内或数据库中标签一致的重复记录数。
indexReloaded	数据库提交后是否成功切换到新内存索引。
errors	逐行校验错误；成功时为空数组。

索引刷新失败：如果数据库已经提交但索引重载失败，success 仍为 true，indexReloaded 为 false。此时应排查日志并调用索引重载接口；数据库数据不会回滚。

4.4 校验失败响应

```
{
  "code": 400,
  "message": "Excel 导入校验失败",
  "data": {
    "success": false,
    "totalRows": 2,
    "inserted": 0,
    "updated": 0,
    "skipped": 0,
    "indexReloaded": false,
    "errors": [
      {"row": 3, "message": "变更类型编码不能为空"}
    ]
  }
}
```

文件为空、扩展名错误、损坏的xlsx等请求级错误会返回code=400且data=null；模型网关失败返回code=503且data=null。

5. 新合同段落预测接口

项目	说明
接口	POST /service/contract-change/predict
完整路径	/glxt-service-contract-change/service/contract-change/predict
Content-Type	application/json
必填请求头	UserId: 实际操作人工号
输入	已经切分好的单个合同段落
结果落库	不落库

5.1 请求报文

```
{
  "paragraph": "需要识别变更类型的新合同段落"
}
```

- paragraph 不能为空。
- 规范化后默认不能超过 2000 字符。

- 服务不自动截断，防止丢失否定词、金额、比例、主体或权利义务信息。

5.2 EXACT 精确命中响应

```
{
  "code": 200,
  "message": "操作成功",
  "data": {
    "matchType": "EXACT",
    "modelVersion": "gen-studio-Qwen3-Embedding-8B-1024-v1",
    "maxSimilarity": 1.0000,
    "changeTypes": [
      { "code": "TYPE01", "score": 1.0000, "supportCount": 1, "level": "HIGH" }
    ],
    "references": [
      {
        "sampleId": 1001,
        "paragraph": "历史合同段落原文",
        "similarity": 1.0000,
        "changeTypeCodes": ["TYPE01"]
      }
    ]
  }
}
```

EXACT 表示规范化文本 Hash 完全相同，因此直接复用历史标签，不调用模型。精确命中属于确定性规则，类型直接标记为 HIGH。

5.3 SEMANTIC 语义匹配响应

```
{
  "code": 200,
  "message": "操作成功",
  "data": {
    "matchType": "SEMANTIC",
    "modelVersion": "gen-studio-Qwen3-Embedding-8B-1024-v1",
    "maxSimilarity": 0.8796,
    "changeTypes": [
      { "code": "35", "score": 0.8462, "supportCount": 3, "level": "HIGH" },
      { "code": "40", "score": 0.6127, "supportCount": 2, "level": "CANDIDATE" }
    ],
    "references": [
      {
        "sampleId": 1006,
        "paragraph": "与新段落最接近的历史段落",
        "similarity": 0.8796,
        "changeTypeCodes": ["35", "40"]
      }
    ]
  }
}
```

5.4 NO_RELIABLE_MATCH 响应

```
{
  "code": 200,
  "message": "操作成功",
  "data": {
    "matchType": "NO_RELIABLE_MATCH",
    "modelVersion": "gen-studio-Qwen3-Embedding-8B-1024-v1",
    "maxSimilarity": 0.5934,
    "changeTypes": [],
    "references": [
      {
        "sampleId": 1012,
        "paragraph": "当前最接近但仍不足以可靠判断的历史段落",
        "similarity": 0.5934,
        "changeTypeCodes": ["TYPE09"]
      }
    ]
  }
}
```

NO_RELIABLE_MATCH 不表示没有找到任何相似段落，而是没有类型达到当前可靠返回规则。
references 仍可能提供排查和人工判断依据。

5.5 响应字段

字段	说明
matchType	EXACT、SEMANTIC 或 NO_RELIABLE_MATCH。
modelVersion	本次使用的向量兼容版本。
maxSimilarity	新段落与召回历史段落中的最高余弦相似度；精确命中为 1。
changeTypes[].code	候选变更类型编码。
changeTypes[].score	该类型获得的权重占全部投票样本权重的比例。
changeTypes[].supportCount	参与投票的历史样本中包含该类型的记录数。
changeTypes[].level	HIGH 或 CANDIDATE。
references	按相似度倒序返回的历史参考段落，最多 5 条。
references[].similarity	新段落与该条历史段落的余弦相似度。

数值位数：相似度和类型得分在 JSON 中最多保留四位小数；内部排序、阈值判断和投票使用完整精度。

6. 内存索引运维接口

6.1 手工重载

项目	说明
接口	POST /service/contract-change/index/reload
请求体	无
UserId	不需要
作用	从 Oracle 重新构建当前模型版本和维度的只读内存快照；不重新生成向量。

调用时机：数据库被人工维护、索引重载失败或需要重新核对索引时调用。正常 Excel 导入成功后会自动重载，一般不需要重复调用。

6.2 查询索引状态

项目	说明
接口	GET /service/contract-change/index/status
请求体	无
UserId	不需要
作用	返回当前实际提供预测服务的内存索引快照状态。

```
{
  "code": 200,
  "message": "操作成功",
  "data": {
    "status": "READY",
    "sampleCount": 8234,
    "modelVersion": "gen-studio-Qwen3-Embedding-8B-1024-v1",
    "vectorDimension": 1024,
    "loadedAt": "2026-08-27T10:15:30.000+0800",
    "errorCount": 0
  }
}
```

loadedAt 的具体 JSON 日期格式由项目统一 Jackson 配置决定；调用方应按日期时间字段解析，不应依赖展示字符串。

6.3 状态含义

状态	含义	预测行为
NOT_READY	应用尚未完成首次加载。	返回 code=503。
READY	全部目标记录加载成功。	正常提供精确和语义预测。
EMPTY	当前模型版本、维度和生效条件下没有数据。	返回 NO_RELIABLE_MATCH，不调用模型。
DEGRADED	部分数据库向量损坏并被跳过。	有可用样本时继续预测；样本数为 0 时返回 503。
LOAD_FAILED	首次查询 Oracle 失败且没有旧索引可用。	返回 code=503。

索引重载先在临时结构中完整构建，再使用 AtomicReference 一次性替换。重载过程中，正在执行的预测继续使用旧快照，不会读到半成品索引。

6.4 Actuator 健康状态

- NOT_READY 和 LOAD_FAILED：DOWN。
- DEGRADED 且 sampleCount=0：DOWN。
- READY、EMPTY，以及仍有可用样本的 DEGRADED：UP。
- 健康检查只检查 Java 服务、数据库自动健康项和内存索引，不主动调用模型推理接口。

7. 统一 Embedding 模型网关

7.1 当前已确认参数

参数	当前值/规则
测试地址	http://aihub-test.citicsinfo.com/embedding/api/qwen3-embedding-local/v1/embeddings

参数	当前值/规则
生产地址	http://aihub.citicsinfo.com/embedding/api/qwen3-embedding-local/v1/embeddings
请求模型名	gen-studio-Qwen3-Embedding-8B
项目模型版本	gen-studio-Qwen3-Embedding-8B-1024-v1
维度	显式请求 1024；平台省略时默认 4096。
编码格式	float
用户头	UserId
认证	Authorization: Bearer <EMBEDDING_API_KEY>
平台额度	每日最高 6000 万 Token；项目仍以 2000 字符控制单段输入。

7.2 Java 发往网关的请求

```
POST <EMBEDDING_URL>
Content-Type: application/json
Authorization: Bearer <服务端 API Key>
UserId: <实际操作人工号>

{
  "model": "gen-studio-Qwen3-Embedding-8B",
  "input": "规范化后的合同段落",
  "dimensions": "1024",
  "encoding_format": "float"
}
```

batch-size 大于 1 时，input 改为字符串数组。当前默认 batch-size=1，以避免超过平台尚未确认的批量上限。

7.3 响应校验

- data 数量必须与输入文本数量一致。
- 批量结果必须通过 data[].index 还原输入顺序；缺失、重复或越界均拒绝。
- 每条 embedding 必须恰好 1024 维。
- 不能包含 null、NaN、无穷值或全零向量。
- Java 端对每条向量执行 L2 归一化后再保存和比较。

7.4 重试规则

网关结果	处理
400/422	请求格式、输入长度或批量参数被拒绝；不重试。
401/403	API Key 错误或无权限；不重试。
404	URL 或部署名称错误；不重试。
429	平台限流；不重试，提示稍后重试。
5xx	模型平台异常；按 max-retries 重试，当前最多重试 1 次。
连接/读取异常	按 max-retries 重试，当前最多重试 1 次。
响应格式或向量异常	不重试，统一转换为 code=503。

8. 业务算法与结果解释

8.1 文本规范化

导入与预测共用同一规范化规则：统一全角空格、统一换行、去除首尾空白并把连续空白压缩为一个空格。不会删除否定词、数字、比例、主体名称或标点。

8.2 L2 归一化和相似度

L2 归一化是把一条向量按相同比例缩放，使其整体长度变为 1，同时保持向量方向不变。这样后续关注的是段落语义方向，而不是向量数值大小。历史向量和新向量都归一化后，逐项相乘再相加就是余弦相似度。

相似度含义： references[].similarity 只表示“新段落与这一条历史段落有多接近”。它不是变更类型得分，也不等于某个类型最终一定成立。

8.3 Top 10 平方加权投票

- 1. 从全部历史样本中保留相似度最高的 10 条。

2. 过滤相似度低于 min-similarity（默认 0.60）的记录。
3. 每条历史样本权重 = similarity^2 ；相似度越高，影响越大。
4. 某类型得分 = 支持该类型的样本权重之和 ÷ 全部投票样本权重之和。
5. 得分不低于 0.55 才返回；得分不低于 0.80 且至少 2 条样本支持时标记 HIGH。

历史样本可以同时包含多个类型，因此各类型 score 之和可能大于 1。这是多标签投票的正常结果，不是概率分布。

8.4 强相似单条候选兜底

当多样本投票没有任何类型达到 0.55，但第一名历史段落相似度达到 0.80 时，服务返回第一名已有的全部类型作为 CANDIDATE。该兜底不标记 HIGH，因为主要证据仍只有一条。返回的 score 仍是统一投票得分，因此可能低于 0.55。

8.5 matchType 与 level

字段	值	说明
matchType	EXACT	规范化文本 Hash 完全相同，直接返回历史标签。
matchType	SEMANTIC	语义检索后至少返回一个类型。
matchType	NO_RELIABLE_MATCH	没有类型满足当前规则；仍可能返回参考段落。
level	HIGH	精确命中，或语义得分 ≥ 0.80 且支持数 ≥ 2 。
level	CANDIDATE	达到候选阈值但未满足 HIGH 条件，或来自强相似兜底。

9. 配置项说明

配置位于 application.yml，可通过环境变量覆盖。当前代码未启用动态刷新；修改配置后需要重启应用。

9.1 服务与数据库

环境变量	默认值	作用
SERVER_PORT	8080	Java 服务监听端口。
ORACLE_URL	本机开发占位地址	Oracle JDBC 连接地址。
ORACLE_USERNAME	glxt	Oracle 用户名。
ORACLE_PASSWORD	change-me	Oracle 密码；生产必须覆盖。
DB_POOL_MAX	10	Hikari 最大连接数。
DB_POOL_MIN	1	Hikari 最小空闲连接数。

9.2 模型网关

环境变量	默认值	作用
EMBEDDING_URL	测试网关完整地址	生产必须覆盖为生产地址。
EMBEDDING_API_KEY	无	Bearer Token；缺少时应用启动失败。
EMBEDDING_MODEL_NAME	gen-studio-Qwen3-Embedding-8B	网关请求体 model。
EMBEDDING_MODEL_VERSION	gen-studio-Qwen3-Embedding-8B-1024-v1	数据库和索引兼容版本。
EMBEDDING_DIMENSION	1024	显式请求维度、响应校验、存储和检索维度。
EMBEDDING_BATCH_SIZE	1	单次网关请求文本数。
EMBEDDING_CONNECT_TIMEOUT_MS	3000	连接超时，毫秒。
EMBEDDING_READ_TIMEOUT_MS	30000	读取超时，毫秒。
EMBEDDING_MAX_RETRIES	1	连接异常和 5xx 的额外重试次数。

9.3 导入和检索

环境变量	默认值	作用
IMPORT_MAX_ROWS	1000	单份 Excel 最大非空数据行数。
IMPORT_MAX_TOTAL_SAMPLES	10000	历史样本物理记录总上限。
SEARCH_RETRIEVE_TOP_K	10	向量检索保留条数。
SEARCH_VOTE_TOP_K	10	最多参与投票的历史记录数。
SEARCH_EVIDENCE_TOP_K	5	最多返回参考段落数。
SEARCH_MAX_PARAGRAPH_LENGTH	2000	规范化段落最大字符数。
SEARCH_MIN_SIMILARITY	0.60	参与投票的最低相似度。
SEARCH_CANDIDATE_THRESHOLD	0.55	类型候选得分阈值。
SEARCH_HIGH_THRESHOLD	0.80	类型高可信得分阈值。
SEARCH_MIN_SUPPORT_COUNT	2	HIGH 所需最低支持样本数。
SEARCH_STRONG_MATCH_THRESHOLD	0.80	单条强相似候选兜底阈值。

配置校验：vote-top-k 和 evidence-top-k 不能大于 retrieve-top-k，candidate-threshold 不能大于 high-threshold；配置不合法时应用启动失败。

10. Oracle 数据结构与数据一致性

第一版只新增 TPIF_HTDLYB 一张业务表，不依赖 TPIF_XBGHTZJ。初始化脚本为 database/oracle/01_schema.sql。

字段	类型	说明
ID	NUMBER(19)	主键，由 SEQ_TPIF_HTDLYB 生成。
YWBW	CLOB	Excel 原始合同段落。
GFBW	CLOB	规范化段落。
TEXT_HASH	VARCHAR2(64)	规范化段落 SHA-256；唯一约束。

字段	类型	说明
BGLX_CODES	VARCHAR2(4000)	去重排序后的英文分号分隔类型编码。
VECTOR_DATA	BLOB	L2 归一化后的 Float32 小端序向量。
VECTOR_DIM	NUMBER(10)	向量维度，当前 1024。
MODEL_VERSION	VARCHAR2(100)	向量兼容版本。
SOURCE_FILE	VARCHAR2(500)	来源 Excel 文件名。
SFSX	NUMBER(1)	1 参与检索，0 停用。
CREATE_TIME	DATE	创建时间。

- 当前 1024 维 Float32 向量固定占 4096 字节。
- 索引只加载 MODEL_VERSION、VECTOR_DIM 与当前配置一致且 SFSX=1 的记录。
- 所有业务 SQL 位于 ContractParagraphMapper.xml，Mapper 接口不使用 @Select 等 SQL 注解。
- CLOB/BLOB 在 XML 中显式指定 jdbcType，避免 Oracle 驱动按错误类型读取。
- TEXT_HASH 唯一约束保证同一规范化段落只有一条物理记录。

10.1 向量存储与加载

Java 使用 float[] 进行计算，写库前按 Float32 小端序编码为 BLOB；应用启动或手工重载时按相同规则解码。BLOB 长度必须等于 VECTOR_DIM×4，否则该记录被跳过，索引状态标记为 DEGRADED。

10.2 事务和并发

- 一份 Excel 的新增和更新在同一个 Spring 事务中完成，任意一条失败整批回滚。
- 导入方法在单实例内使用 synchronized，同一时刻只处理一份 Excel。
- Oracle 查重按 500 个 Hash 一批查询，避免逐行查询并规避 IN 列表过长。
- 多实例部署时，当前实例导入后只会刷新自身内存索引；第一版因此明确按单实例部署。

11. 部署、启动与模型迁移

11.1 首次部署顺序

1. 确认测试或生产模型网关地址、API Key、模型名称、版本和维度。
2. 确认应用主机到测试 10.63.36.231:80 或生产 10.121.148.231:80 网络可达。
3. 使用业务库账号执行 database/oracle/01_schema.sql。
4. 设置 Oracle 和 Embedding 环境变量。
5. 使用 Java 8 执行 Maven 测试和打包，启动 Spring Boot Jar 或应用 Docker 镜像。
6. 检查 Actuator 与 index/status；首次空库应为 EMPTY。
7. 导入少量历史样本，核对 inserted、indexReloaded 和 sampleCount。
8. 完成精确、相似和无关段落验证后再全量导入。

11.2 启动示例

```
$env:JAVA_HOME='D:\tools\Java\jdk1.8.0_481'
$env:ORACLE_URL='jdbc:oracle:thin:@10.0.0.10:1521:ORCL'
$env:ORACLE_USERNAME='glxt'
$env:ORACLE_PASSWORD='<数据库密码>'
$env:EMBEDDING_URL='<测试或生产完整 Embedding 地址>'
$env:EMBEDDING_API_KEY='<API Key>'
$env:EMBEDDING_MODEL_NAME='gen-studio-Qwen3-Embedding-8B'
$env:EMBEDDING_MODEL_VERSION='gen-studio-Qwen3-Embedding-8B-1024-v1'
$env:EMBEDDING_DIMENSION='1024'

mvn test
mvn -DskipTests package
java -jar target/glxt-service-contract-change-1.0.0.jar
```

API Key 保存：开发环境可放在 IDEA Run Configuration 的 Environment variables 中；生产环境应由部署平台的密钥或环境变量机制注入。不得写入 application.yml、代码、Git、Word 示例或日志。

11.3 模型或维度切换

1. 为新模型或新维度设置新的 EMBEDDING_MODEL_VERSION。
2. 设置平台确认的 EMBEDDING_MODEL_NAME 和 EMBEDDING_DIMENSION。
3. 在维护窗口使用原历史 Excel 重新导入全部样本。
4. 相同 Hash、相同类型的旧记录会更新向量、维度、模型版本并重新启用。

- 5. 确认 index/status 中的模型版本、维度和样本数正确。
- 6. 使用人工确认样本重新验证阈值，再开放预测。

不同模型或不同维度的向量禁止混合比较。即使模型别名未变化，只要平台底层模型发生变化，也必须修改 MODEL_VERSION 并重新生成全部历史向量。

12. 错误处理、日志与安全

12.1 常见业务错误

现象	业务码	排查方向
UserId 请求头不能为空	400	导入或预测请求缺少 UserId。
只支持 xlsx 格式文件	400	上传了 .xls、csv 或其他扩展名。
Excel 文件不能超过 20MB	400	文件超过 Multipart 限制。
Embedding 网关认证或权限失败	503	检查 API Key、模型授权和配置来源。
Embedding 接口地址或模型部署名称错误	503	检查完整 URL 和部署名称。
Embedding 请求格式、输入长度或批量参数被拒绝	503	检查 model、dimensions、input 和 batch-size。
历史段落向量索引不可用	503	查看 index/status 和应用启动日志。
系统处理失败，请联系管理员	500	查看服务端错误日志和数据库状态。

12.2 日志规则

- 记录导入、事务、索引、模型调用和预测的数量、状态与耗时。
- 合同正文只记录规范化文本 SHA-256，不记录完整内容。
- 不记录 API Key、UserId、请求体、模型响应体或向量。
- 生产环境不要开启 Mapper 或 RestTemplate DEBUG，避免输出 CLOB、BLOB 或网关请求信息。

12.3 安全要求

- API Key 只保存在服务端部署环境，调用方无权指定或覆盖。
- 历史合同段落属于敏感业务数据，应限制导入、预测和参考段落响应的访问权限。
- references 会返回历史段落原文，上层网关必须落实鉴权和访问审计。
- 回滚脚本会 PURGE 删除表及数据，生产环境必须经过审批后执行。

13. 联调与验收清单

验收项	验收标准
数据库	表、Sequence、索引创建成功；CLOB/BLOB 可正常插入和读取。
配置	API Key 未写入代码；模型名称、版本、维度与平台确认值一致。
网络	应用主机可访问对应环境的 Embedding 网关。
模型契约	单条请求返回 200，data[0].embedding 长度为 1024。
导入	正确文件可导入；错误表头、空段落、标签冲突可明确返回。
幂等	同段落同标签重复导入计入 skipped，不新增记录。
事务	模型失败或数据库中途失败时不会出现半批数据。
索引	重启后自动恢复；sampleCount 与当前有效数据库记录数一致。
精确预测	相同规范化段落返回 EXACT 且不调用模型。
语义预测	相似段落返回类型、score、level 和参考段落。
无可靠匹配	无关段落返回 NO_RELIABLE_MATCH，不返回假类型。
错误处理	401/403/404/422/429/5xx 和超时能转换为明确业务错误。
性能	1 万条 1024 维内存检索达到百毫秒级目标；完整预测 P95 以网关实测为准。
安全	日志中无正文、向量、API Key 和 UserId。

阈值验收：更换模型后不能仅凭模型名称调整阈值。应使用人工确认样本统计实际相似度和类型结果，再通过环境变量调参。

14. 附录：调用示例与 Excel 模板

14.1 PowerShell 上传 Excel

```
curl.exe -X POST `
  "http://localhost:8080/glxt-service-contract-change/service/contract-change/samples/
  import" `
  -H "UserId: T024818" `
  -F "file=@D:\data\合同历史段落.xlsx"
```

14.2 PowerShell 预测

Windows PowerShell 调用原生 curl.exe 时，复杂 JSON 建议保存为 UTF-8 文件，避免命令行引号被错误拆分。

```
Set-Content -Path .\predict.json `
  -Value '{"paragraph":"需要识别变更类型的新合同段落"}' `
  -Encoding UTF8

curl.exe -X POST `
  "http://localhost:8080/glxt-service-contract-change/service/contract-change/predict" `
  -H "Content-Type: application/json" `
  -H "UserId: T024818" `
  --data-binary "@predict.json"
```

14.3 索引接口

```
curl.exe -X GET `
  "http://localhost:8080/glxt-service-contract-change/service/contract-change/index/
  status"

curl.exe -X POST `
  "http://localhost:8080/glxt-service-contract-change/service/contract-change/index/
  reload"
```

14.4 模型网关关联调请求

以下仅供服务端联调。不要把真实 API Key 保存到脚本、截图或文档中。

```
{
  "model": "gen-studio-Qwen3-Embedding-8B",
  "input": "需要转换为向量的合同段落",
  "dimensions": "1024",
  "encoding_format": "float"
}

curl.exe -X POST "<EMBEDDING_URL>" `
  -H "Content-Type: application/json" `
  -H "Authorization: Bearer <EMBEDDING_API_KEY>" `
```

```
-H "UserId: T024818" `
--data-binary "@embedding-request.json"
```

14.5 关键文件索引

文件	作用
README.md	项目边界、配置、启动和核心流程说明。
src/main/resources/application.yml	运行配置与默认参数。
ContractChangeController.java	四个业务接口定义。
ContractParagraphImportService.java	Excel 解析、校验、向量化与导入流程。
ContractParagraphPredictionService.java	精确匹配、语义检索与投票规则。
ParagraphVectorIndexService.java	Oracle 向量加载、状态和 Top-K 检索。
HttpEmbeddingClient.java	统一模型网关请求、校验和重试。
ContractParagraphMapper.xml	全部业务 SQL。
database/oracle/01_schema.sql	Oracle 表、Sequence、索引与字段备注。

文档基准：本文档根据 2026 年 8 月 27 日当前项目代码生成。后续接口字段、模型版本、阈值或部署方式调整时，应同步更新本文档。